Module Processus Décisionnel en Big Data

TD : choix d'architecture et chaîne décisionnelle en Big Data

Objectifs

- Choisir entre Lambda, Kappa et Médaillon à partir d'un besoin métier
- Dessiner la chaîne décisionnelle, de la source jusqu'à la décision
- Justifier le choix et en citer les limites

2. Rappels et méthode

Architecture	Principe	Se choisit plutôt quand
Lambda	Batch layer (calcul exact) + speed layer (vues rapides) + serving layer	Il faut à la fois de la fraîcheur et de l'exactitude, et l'équipe accepte deux logiques de calcul
Kappa	Un seul pipeline de streaming sur un journal d'événements rejouable	La décision est quasi immédiate et une seule logique de calcul suffit
Médaillon	Couches Bronze, Silver et Gold de qualité croissante dans un lakehouse	On veut organiser la qualité des données ; s'associe à un traitement batch ou streaming

Cas 1 : détection de fraude bancaire

Contexte. Une banque de détail (fictive) propose le paiement par carte en magasin et sur Internet, 24 h/24. Chaque paiement doit être accepté, refusé ou soumis à une authentification renforcée avant que le client ne quitte la caisse ou la page de paiement.

Données disponibles

- Paiements : montant, commerçant, pays, heure
- Historique du client sur 12 mois
- Liste noire de commerçants

Contraintes

- Décision en moins d'une seconde
- Règles de fraude et modèle de scoring modifiés chaque semaine
- Historique conservé pour ré-entraîner le modèle et justifier une décision en cas de litige

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Cas 2 : e-commerce pendant le Black Friday

Contexte. Une boutique en ligne (fictive) organise trois jours de promotions. L'équipe marketing veut suivre le chiffre d'affaires en direct pour ajuster les offres dans la journée. La direction financière exige des chiffres exacts pour la clôture.

Données disponibles

- Commandes, paniers abandonnés, clics
- Retours et annulations
- Corrections de prix saisies après coup

Contraintes

- Vue en direct rafraîchie en quelques secondes pour le marketing
- Chiffres exacts une fois les retours, annulations et corrections pris en compte
- Fort pic de trafic pendant les promotions

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Cas 3 : maintenance prédictive d'éoliennes

Contexte. Un exploitant de parcs éoliens (fictif) suit des milliers de capteurs (vibrations, température, vitesse du vent). Il veut prédire les pannes quelques jours à l'avance pour planifier les interventions et commander les pièces.

Données disponibles

- Mesures de capteurs toutes les secondes
- Journaux des machines
- Historique des pannes

Contraintes

- Capteurs défaillants, doublons et valeurs aberrantes fréquents
- Une alerte par jour suffit
- Les mêmes données préparées doivent servir à plusieurs modèles et tableaux de bord
- Les transformations doivent pouvoir être rejouées quand une règle de nettoyage est corrigée

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Cas 4 : livraison de repas

Niveau 2

Contexte. Une plateforme de livraison de repas (fictive) affiche l'heure d'arrivée estimée et attribue chaque commande au livreur le plus adapté. Les équipes veulent aussi des rapports hebdomadaires et ré-entraîner le modèle d'estimation.

Données disponibles

- Positions GPS des livreurs (toutes les quelques secondes)
- Commandes et temps de préparation des restaurants
- Données de trafic

Contraintes

- Estimation et affectation à jour en quelques secondes
- Données GPS de qualité inégale (points aberrants, pertes de signal)
- Rapports et ré-entraînement fondés sur un historique propre

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Cas 5 : hôpital universitaire

Niveau 3

Contexte. Un hôpital universitaire (fictif) veut centraliser les données de ses services pour piloter l'activité (occupation des lits, durée de séjour) et identifier chaque matin les patients à risque de réadmission.

Données disponibles

- Dossier patient informatisé
- Résultats de laboratoire
- Facturation et rendez-vous

Contraintes

- Données de santé sensibles
- Un patient peut demander l'effacement de ses données (RGPD ou loi 09-08 selon le pays)
- Accès et modifications traçables pour les audits
- Analyses consultées chaque matin

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Question bonus : comment appliquer une demande d'effacement dans toutes les couches de stockage ?

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Cas 6 : plateforme de vidéo à la demande

Niveau 3

Contexte. Une plateforme de vidéo à la demande (fictive) recommande en temps réel la prochaine vidéo à chaque utilisateur. Elle doit aussi calculer chaque mois la rémunération exacte des ayants droit à partir des lectures valides.

Données disponibles

- Événements de lecture (démarrage, pause, fin)
- Catalogue et contrats de rémunération
- Signalements de lectures frauduleuses (robots)

Contraintes

- Recommandation affichée en moins d'une seconde
- Calcul mensuel auditable et contestable par les ayants droit
- Les lectures frauduleuses détectées après coup doivent être retirées du calcul

Questions

1. Quelle est la décision à prendre et quel délai est acceptable entre l'événement et la décision ?
2. Complétez la fiche de la chaîne décisionnelle ci-dessous.
3. Quelle architecture retenez-vous : Lambda, Kappa, Médaillon ou une combinaison ?
4. Justifiez : pourquoi ce choix, et pourquoi pas les autres ?
5. Citez deux limites ou points de vigilance de votre choix.

Question bonus : comment garantir que la recommandation et le rapport mensuel utilisent la même définition d'une lecture valide ?

Étape de la chaîne	Vos choix (outils, rôle)
Sources	
Ingestion	
Stockage	
Traitement	
Machine learning	
Restitution / décision	
Architecture retenue	

Partie 3 – Énoncés des exercices

Exercice 1 – Vrai ou faux ?

Pour chaque affirmation, répondre **Vrai** ou **Faux** et justifier en une phrase.
a) Le Data Lake applique un contrôle de schéma strict à l'écriture.
b) Delta Lake ajoute des transactions ACID au-dessus d'un stockage objet.
c) L'architecture Kappa utilise deux pipelines séparés, un batch et un streaming.
d) La couche Gold contient la donnée la plus proche de la source, non transformée.
e) Un Data Lake mal gouverné peut devenir un « data swamp ».

Exercice 2 – Associer chaque situation à l'architecture adaptée

Relier chaque situation (1, 2, 3) à l'une des architectures suivantes : **Lambda**, **Kappa**, **Médaillon**.

1. Besoin d'une exactitude garantie, avec possibilité de recalculer tout l'historique en batch.
2. Latence de décision quasi temps réel, avec une seule logique métier à maintenir.
3. Organiser le stockage en couches de qualité croissante au sein d'un même Lakehouse.

Exercice 3 – Mini étude de cas : covoiturage

Une startup de covoiturage reçoit deux flux de données :

- Les positions GPS de ses véhicules, transmises en continu par l'application mobile, à haute fréquence.
- Un export comptable mensuel envoyé par son partenaire de facturation, au format CSV.

Question : pour chacune des deux sources, l'ingestion doit-elle être pensée en mode batch ou en mode streaming ? Justifier en une phrase par source.

Exercice 4 – Compléter la chaîne de valeur décisionnelle

La chaîne de valeur est la suivante :
Ingestion → ? → Analytics → ? → Gouvernance
Questions : quels sont les deux maillons manquants ? Dans quel chapitre du module chacun est-il traité ?

Exercice 5 – Chasse à l'erreur : deux affirmations à corriger

> *« Le Lakehouse repose sur le stockage HDFS uniquement et ne peut jamais être utilisé avec un stockage cloud comme S3. De plus, contrairement au Data Lake, le Lakehouse applique un schema-on-write strict qui empêche toute ingestion de données semi-structurées. »*

Consigne : ce court paragraphe contient deux erreurs techniques. Les identifier et les corriger, en s'appuyant sur le cours du chapitre 1.

Exercice 6 – Modèles de stockage et évolutivité

Contexte : une entreprise de commerce en ligne stocke ses transactions dans une base SQL classique. Lors des soldes, le système ralentit fortement : saturation des I/O et verrous sur les tables.

1. Expliquer la différence entre évolutivité verticale (scale-up) et évolutivité horizontale (scale-out).
2. Pourquoi l'architecture SQL classique atteint-elle ses limites dans ce contexte ?
3. Proposer une stratégie de migration hybride (SQL / NoSQL / Cache) pour maintenir de bonnes performances.

Exercice 7 – La règle des 5V du Big Data

Pour chaque scénario, identifier le ou les V prédominants (**Volume, Vélocité, Variété, Véracité, Valeur**) et justifier.

1. Analyse en temps réel de flux vidéo de caméras routières pour détecter des accidents.

2. Centralisation de dossiers médicaux : texte libre, imagerie DICOM, audio de consultations, données de capteurs cardiaques.
3. Agrégation de 10 ans de tickets de caisse pour identifier des tendances d'achat à long terme.

Exercice 8 – Étude de cas : LogiTransport

LogiTransport gère 5 000 camions. Chaque camion envoie toutes les 5 secondes sa position GPS, la température de sa remorque et l'état moteur (message ≈ 500 octets), vers un serveur MySQL centralisé qui s'effondre sous la charge (≈ 1000 requêtes/s en continu).

1. Évaluer le volume de données généré par jour.
2. Identifier le goulot d'étranglement de l'architecture actuelle.
3. Proposer un schéma d'architecture cible : ingestion temps réel, stockage chaud (requêtes/alertes), stockage froid (historique, maintenance prédictive).
4. Argumenter le choix NoSQL / base orientée séries temporelles pour le stockage chaud, et l'apport de la réplication / du sharding.